Universidad Externado de Colombia

Departamento de Matemáticas
Ciencia de Datos

Aplicación PCA y PPCA

Entrega final

Fincaraiz Bogotá.

Autores

Juan Pablo Carrillo Hortua
juan.carrillo6@est.uexternado.edu.co

Mariana Uribe Vanegas
mariana.uribe2@est.uexternado.edu.co

Director / Docente

Julian Fernando Sanchez Lopez
julian.sanchez@uexternado.edu.co

Asignatura

Profundización en Estadística

Bogotá D. C., Colombia
12 de noviembre de 2026

Índice

Contenido ii

1. Pregunta y datos 1

2. Preparación 2
2.1. Delimitación de objetivos . . . 2
2.2. Tratamiento de valores nulos . . . 2
2.3. Tratamiento de valores atípicos . . . 3
2.4. Preparación de datos para el modelado . . . 4

3. Exploración 4

4. Distribuciones 5

5. Inferencia multivariable 6

6. Regresión lineal múltiple 7
6.1. Regresión ganadora de la primera entrega . . . 7
6.2. Regresión ajustada con componentes principales . . . 8

7. PCA y PPCA 9
7.1. PCA . . . 9
7.1.1. Variables a utilizar en PCA . . . 9
7.1.2. Análisis de escala para PCA . . . 10
7.1.3. PCA estandarizando las variables sin transformar . . . 11
7.1.4. PCA estandarizando las variables transformadas . . . 12
7.2. PPCA . . . 13
7.2.1. PPCA estandarizando las variables sin transformar . . . 14
7.2.2. PPCA estandarizando las variables transformadas . . . 15
7.3. Comparar reconstrucciones . . . 15

8. Conclusión 17

Referencias 18

1. Pregunta y datos

Se define la pregunta como **¿Cuáles son las principales características que potencian el valor de una vivienda en la ciudad?**; esta pregunta se responderá con datos extraídos mediante web scraping del portal FincaRaiz.com. El conjunto inicial consta de 31.252 observaciones. El conjunto inicial consta de las variables de la siguiente tabla, y durante el desarrollo del proyecto se irán descartando o creando variables.

Variable	Unit	Description
`listing_id`	id	Unique identifier of the listing on FincaRaíz.
`operation`	category	Transaction advertised: `venta` (sale) or `arriendo` (rent).
`property_type`	category	Class of property: `apartamento`, `casa`, `oficina`, `bodega`, `local`, `lote`, and similar.
`price_amount`	COP	Asking price published in the listing.
`price_currency`	category	Currency the asking price is quoted in.
`admin_fee`	COP / month	Monthly building administration fee (*administración*).
`total_monthly_cost`	COP / month	Rent plus administration fee; defined for rental listings.
`price_per_m2`	COP / m^2	Asking price divided by built area.
`area_built_m2`	m^2	Constructed area of the property.
`area_private_m2`	m^2	Private interior area of the unit.
`bedrooms`	count	Number of bedrooms.
`bathrooms`	count	Number of bathrooms.
`parking_spaces`	count	Number of parking spaces included with the property.
`stratum`	ordinal 1–6	Colombian socio-economic stratum assigned to the address.
`floor`	floor number	Floor of the building on which the unit sits.
`floors_total`	count	Number of floors in the building.
`age_bracket_code`	ordinal 0–5	Age of the property as a bracket: 0 brand new, 1 under 1 year, 2 = 1–8, 3 = 9–15, 4 = 16–30, 5 over 30 years.
`age_bracket_label`	category	Spanish text label of the age bracket.
`construction_state`	category	Condition declared in the listing: `Usado`, `Excelente estado`, `En construcción`, and similar.
`city`	name	Municipality where the property is located.
`locality`	category	Bogotá *localidad* containing the property.
`neighborhood`	name	Neighbourhood (*barrio*) of the property.
`address_text`	text	Street address as published in the listing.
`latitude`	degrees (WGS84)	Latitude of the property's map location.
`longitude`	degrees (WGS84)	Longitude of the property's map location.

Continúa en la página siguiente

Tabla 1 (continuación)

Variable	Unit	Description
`amenities`	list (|-separated)	Amenities and features attributed to the property or its building.
`agency_name`	name	Real-estate agency publishing the listing.
`publisher_type`	category	Kind of publisher: `inmobiliaria` (agency) or `desarrollador` (developer).
`published_at`	date (YYYY-MM-DD)	Date the listing was first published.
`updated_at`	date (YYYY-MM-DD)	Date the listing was last updated.
`source_url`	URL	Web address of the listing.

Tabla 1. Diccionario de variables del conjunto de datos de FincaRaíz.

2. Preparación

La preparación constó de 4 fases marcadas: delimitación de objetivos, tratamiento de valores nulos, tratamiento de valores atípicos y preparación de datos para el modelado.

2.1. Delimitación de objetivos

Originalmente la base recolectada tenía propiedades de diferentes tipos, incluso comerciales, como lo son oficinas, bodegas, edificios, etc. Como el objetivo del proyecto se centra netamente en las viviendas de Bogotá, se optó por eliminar dichos registros; esto supuso una reducción de $\approx 26,87\,\%$ en el tamaño del conjunto de datos. Adicionalmente, se eliminaron columnas que no eran útiles para la inferencia estadística, como lo son listing_id, operation (todas eran ventas, por lo tanto, era constante), source_url, total_monthly_cost (siempre era 0, ya que no eran alquileres), address_text (dato libre complicado de procesar, se reemplazó con las coordenadas).

2.2. Tratamiento de valores nulos

En la siguiente gráfica se hace un resumen de cómo se trataron los valores nulos. Vale la pena aclarar que en aquellas variables donde se utilizó una imputación de tipo MICE se verificó el mecanismo MAR; además, las que se reportan como bussines_logic son aquellas que se imputaron siguiendo alguna convención del mercado o del contexto del mercado de Colombia (para más detalles, consulte notebooks/data_cleaning.ipynb).

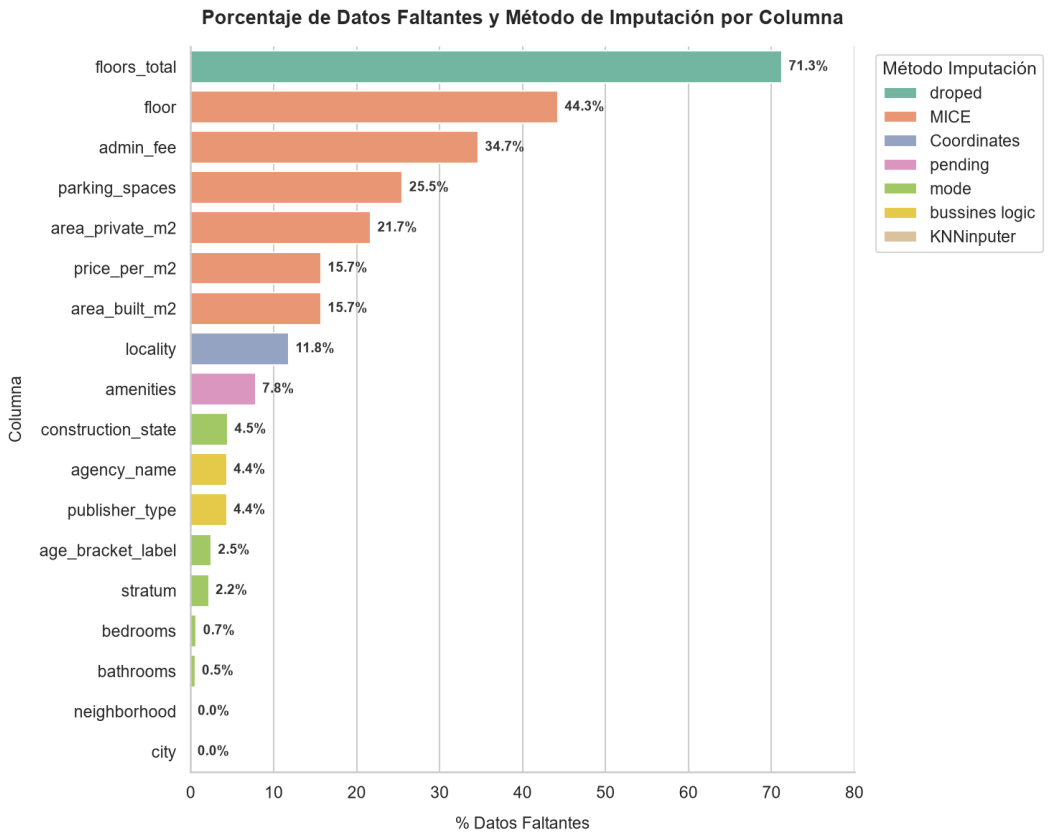


Figura 1. Resumen de tratamiento de valores nulos.

2.3. Tratamiento de valores atípicos

En esta sección no se usó simplemente el criterio clásico de 1.5 veces el IQR; esto debido a que el rango de la variable era tan amplio y presentaba valores tan extremos que el límite inferior quedaba en números negativos (evidentemente ilógico en datos de precio y área), por lo que se generaron dos filtros previos. El primero constaba en eliminar inmuebles que tuvieran un precio fuera del intervalo $(30.000.000, 1.000.000.000.000)$, esto para eliminar los inmuebles sospechosamente baratos y costosos sin eliminar inmuebles reales; de ahí que los límites se fijen en precios poco plausibles. Lo mismo se hizo para la variable área construida y privada, que se les definió el mismo rango válido: $(10, 5.000)$. Una vez realizada esta eliminación inicial, se utilizó un criterio sobre los atípicos extremos $(q_i \pm 3(\text{IQR}))$, esto con el objetivo de no eliminar inmuebles válidos pero extremadamente grandes o costosos, como propiedades de lujo. Después de todo este procedimiento, el tamaño final del conjunto es de 20.253 registros, siendo aproximadamente un 35 % más pequeño que el original (aunque recuerde que la eliminación inicial no se consideró pérdida de información, sino delimitación de datos).

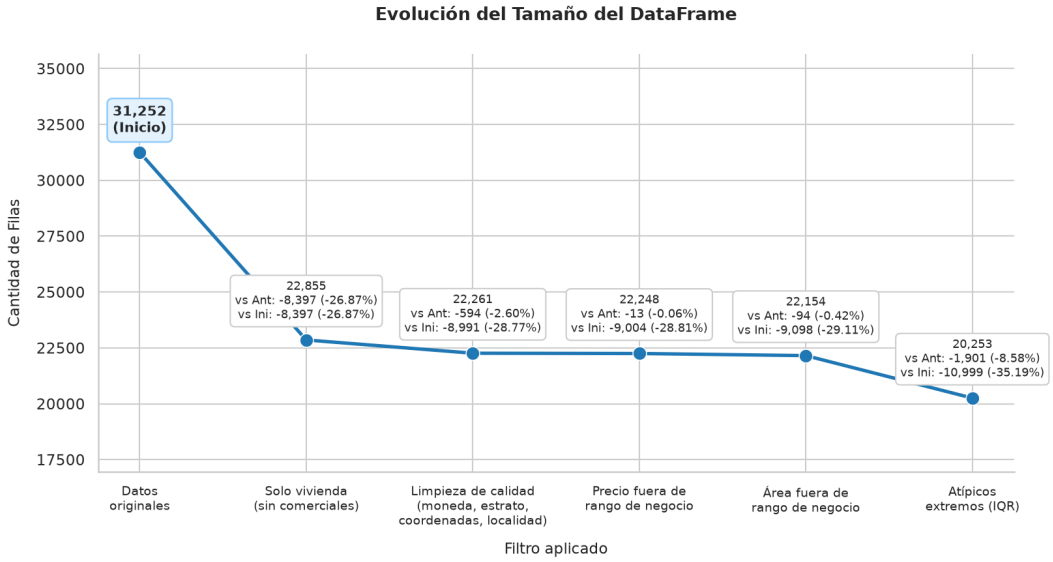


Figura 2. Resumen de la evolución del tamaño del conjunto conforme se procesa.

2.4. Preparación de datos para el modelado

Se generaron 3 nuevas columnas: n_amenities, Trans Publico cerc y Zona Residencial. Las 3 vienen de procesar las amenidades que el portal reportaba por inmueble; la primera describe cuántas amenidades fueron reportadas, y las otras 2 indican si esa amenidad fue reportada (variables binarias).

Además, las columnas categóricas se codificaron utilizando OneHot cuando eran nominales y de baja cardinalidad, tal como el tipo de publicador, y con frequency encoding cuando la variable era nominal pero con alta cardinalidad, como lo es la localidad.

3. Exploración

Como hallazgos generales, se encontró que en la muestra los estratos más comunes eran el 3, 4 y 6; este último podría suponer un sesgo en la muestra al tener tanta representatividad de viviendas que en realidad son una minoría. Asimismo, los inmuebles suelen rondar entre los 16 a 30 años, ser usados y las localidades más comunes de la muestra son Usaquén y Suba por un amplio margen; esto indica que la muestra posiblemente sea más representativa de esas localidades y menos representativa del sur de la ciudad, pues no se cuenta con tantos datos de dicha zona.

En cuanto a los hallazgos bivariados, los más claves constan en la identificación de variables asociadas con el precio, tales como el estrato y la localidad, donde los resultados coinciden con lo esperado: estrato 6 es el más costoso y localidades como

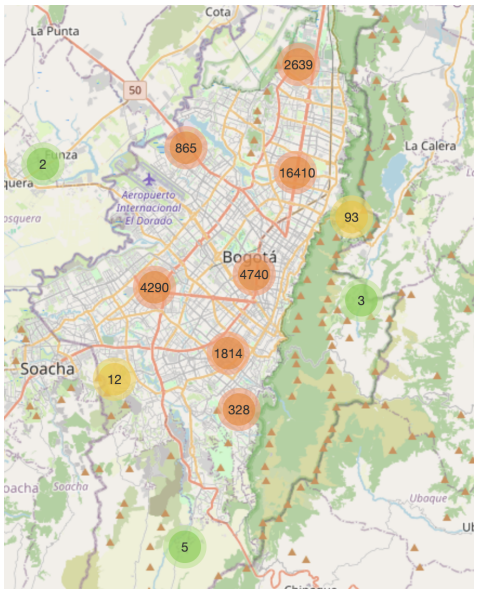
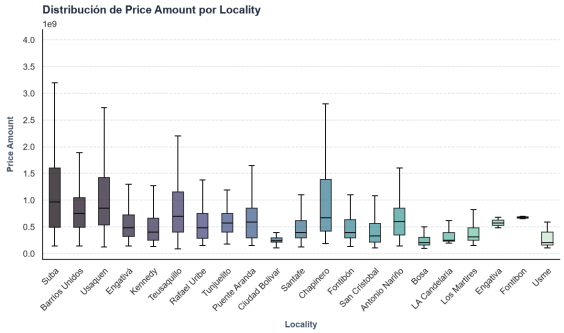
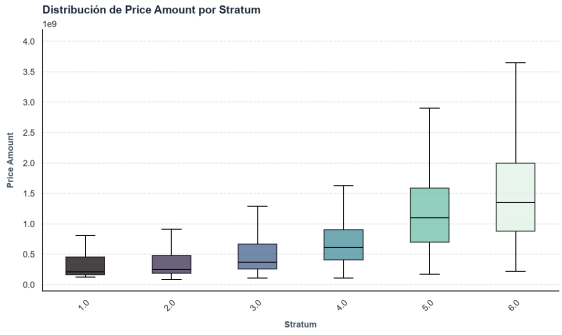


Figura 3. Mapa de clusters de las viviendas de la muestra: la mayor masa está concentrada entre Suba y Usaquén, mientras que al sur hay pocas viviendas.

Usaquén son las más costosas, mientras otras como Bosa son significativamente más económicas, todas ellas respaldadas por pruebas de hipótesis. No se ahondará más, ya que se ha expuesto en documentos anteriores.



(a) Cómo se comporta el precio en cada localidad.



(b) Comportamiento del precio en cada estrato.

Figura 4. Comportamiento del precio de las viviendas por localidad y por estrato.

4. Distribuciones

En esta sección se hace un muy breve resumen de las distribuciones conjuntas continuas más importantes; para ver las demás puede remitirse al repositorio en `notebooks/joint_eda.ipynb` o `notebooks/joint_distributions.ipynb`, o a los informes anteriores que también se encuentran en la carpeta `docs` del repositorio.

La distribución conjunta más clave viene de cómo cambia el comportamiento del precio al fijar un área construida.

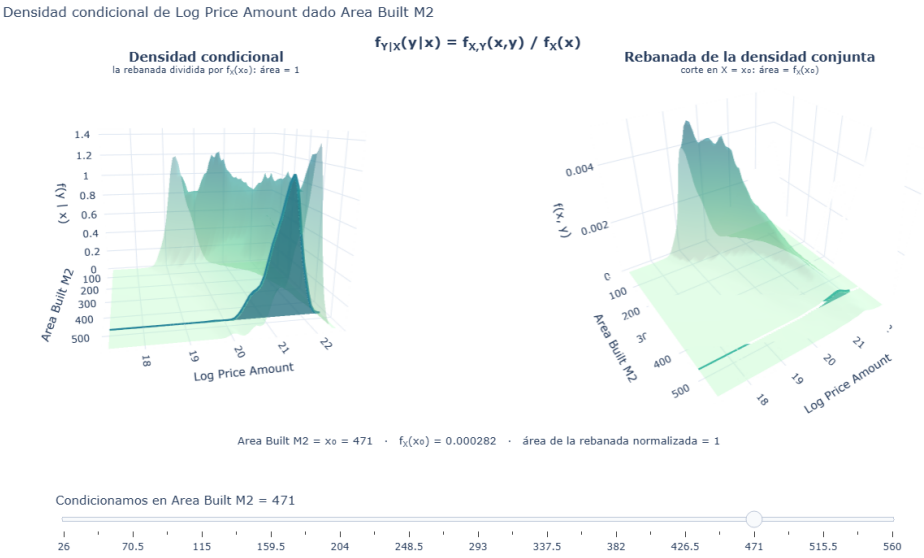


Figura 5. Densidad de log price dada el área construida.

Conforme aumenta el área construida, la probabilidad condicional muestra algo muy claro, y es que los precios altos se hacen más probables y los bajos más improbables; el efecto contrario ocurre al disminuir el área construida. Esto respalda lo que se esperaría en el contexto, pues es lógico que a mayor metraje, mayor precio. Además, se logra apreciar que, conforme el precio y el área aumentan, es menos probable encontrar viviendas con esas características al tiempo.

5. Inferencia multivariable

Se plantearon diferentes pruebas de hipótesis, de las cuales las más claves constan en el hallazgo de la diferencia significativa que tienen los vectores de medias de distintas zonas. Específicamente, se halló que las viviendas de Chía y Soacha son estadísticamente diferentes de las de Bogotá; más específicamente, las de Soacha son más económicas y las de Chía, más costosas.

Comparación	T^2	**Estadístico** F	p**-valor**	**Se rechaza** H_0
Bogotá vs. Chía	2640.11	1313.40	1.02×10^{-114}	Sí
Bogotá vs. Soacha	3647.79	1813.47	2.95×10^{-117}	Sí
Norte vs. Sur	7211.90	2403.29	0	Sí

Tabla 2. Resumen de la prueba T^2 de Hotelling con S_{diff} para las tres comparaciones. Recuerde que S_{diff} no supone que la covarianza es igual entre grupos.

De ahí nacieron diferentes perfiles de clientes, los cuales son los siguientes.

Zona	Descripción	Posibles clientes
Chía	Zona exclusiva, de estratos 5 y 6 y con alta área construida.	Presupuesto alto; buscan sectores exclusivos y amplios.
Norte de Bogotá	Inmuebles de buen tamaño a un precio considerablemente menor que en Chía.	Presupuesto medio; buscan inmuebles de buen tamaño.
Sur de Bogotá	Más asequible que el norte, con un buen metraje medio.	Presupuesto menor; buscan vivir en el casco urbano.
Soacha	La opción más económica y con los inmuebles más pequeños.	Presupuesto apretado; buscan viviendas asequibles.

Tabla 3. Segmentaciones del mercado y posibles perfiles de clientes (adaptado de la entrega 2).

6. Regresión lineal múltiple

Se probó con múltiples modelos lineales; en esta sección se hará énfasis en 2 de ellos: el modelo que se seleccionó como ganador en la primera entrega y un experimento reciente con un conjunto preprocesado con PCA.

6.1. Regresión ganadora de la primera entrega

Esta regresión utilizaba el conjunto de datos que se preparó para el modelamiento; además volvió simétricas variables sesgadas como el precio (la variable objetivo) y el área construida con una transformación logarítmica, y adicionalmente agregó un término cuadrado `latitude_sq`. Dicho esto, el esquema general del modelo luciría de la siguiente manera.

$$\log(\texttt{price_amount}) = \beta_0 + \cdots + \beta_p \log(\texttt{area_built_m2}) + \beta_{p+1}\, \texttt{latitude}^2 \qquad (1)$$

Se omiten las demás variables, ya que son las mismas codificaciones que se expusieron anteriormente; para más detalles, remítase a `notebooks/model_OLS.ipynb`.

Este modelo tuvo un muy gran ajuste, pues presentó un $R^2 \approx 0.902$ y un $R^2_{\text{Adj}} \approx 0.902$, lo cual sugiere que el rendimiento del modelo no fue inflado por variables que solo aportasen ruido o asociaciones espurias. Asimismo, se rechazó la prueba global F; sin embargo, no fue posible cumplir con los supuestos de la regresión lineal. Jarque-Bera rechazó la normalidad de los residuos, Breusch-Pagan rechazó la homocedasticidad, esto a pesar de que el gráfico de residuales frente a valores ajustados fue el que más parecía una nube amorfa centrada en 0; no obstante, Durbin-Watson fue ≈ 1.91, lo cual sugiere

la ausencia de autocorrelación de primer orden.

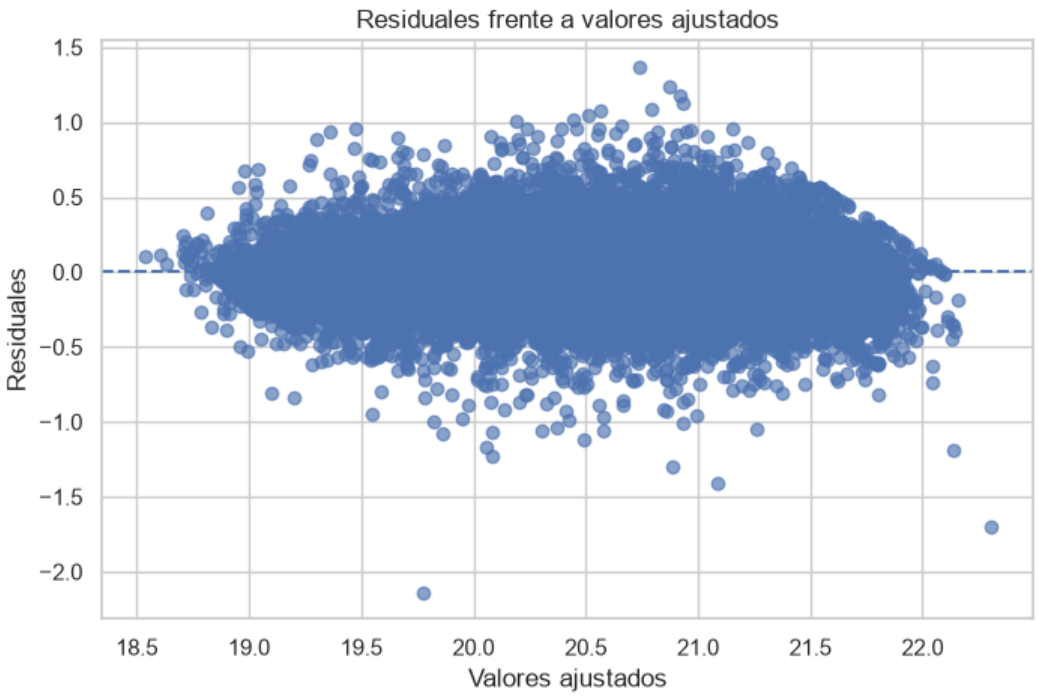


Figura 6. Gráfico de residuos del mejor modelo de la primera iteración. A pesar de lucir mucho mejor que los gráficos de los demás modelos y de tener forma de nube centrada en 0, las pruebas de hipótesis rechazaron los supuestos de la regresión lineal.

6.2. Regresión ajustada con componentes principales

Este experimento constó en generar componentes principales, esto con el fin de observar si el modelo tenía un mejor rendimiento, aunque a costa de interpretabilidad. Los dos modelos principales que se probaron fueron uno que fue solo ajustado con las primeras 5 componentes principales de las variables numéricas de rango amplio o continuas (más detalle en la sección dedicada a PCA) y uno que usó esas 5 componentes más las variables categóricas que se omitieron en el proceso del PCA. Contrario a lo que se pensó en principio, estos modelos tuvieron un peor ajuste que el modelo ganador de la primera iteración, con un $R^2 \approx 0.766$ y $R^2 \approx 0.812$, respectivamente; adicionalmente, tampoco se cumplió ninguno de los supuestos, y junto a esto las nubes de sus gráficos de residuos mostraban una leve curvatura, sugiriendo la falta de algún término cuadrático; sin embargo, como se perdieron las variables numéricas originales, se decidió no aplicar ningún término cuadrado en las componentes.

Este decremento en el rendimiento posiblemente pasó por el funcionamiento del PCA, que, recordemos, busca maximizar $\text{máx}_{\mathbf{a}}\ \mathbf{a}^T\mathbf{S}\mathbf{a}$, es decir, busca las direcciones que maximizan la variabilidad del conjunto de características (unos ejes que describan mejor las características); por lo tanto, esos ejes no son necesariamente aquellos que

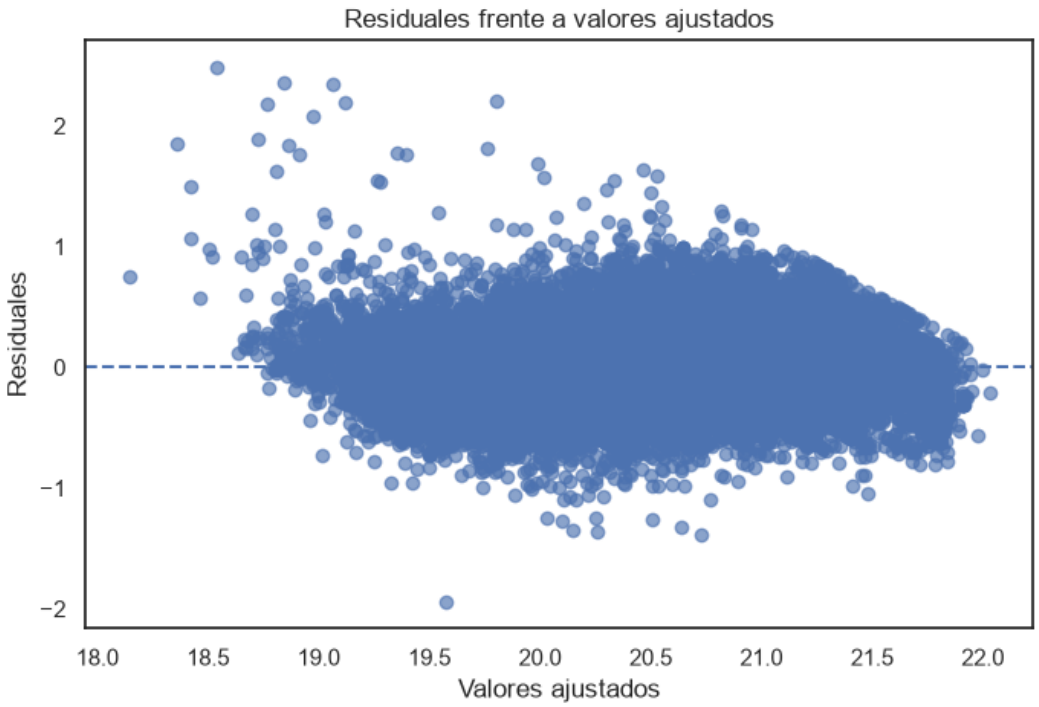


Figura 7. Gráfico de residuos del modelo que usa las componentes principales más las categorías. Note su leve curvatura en la parte inferior derecha y cómo los puntos parecieran sesgarse en la esquina superior izquierda, sugiriendo un fallo sistemático, posiblemente por pérdida de información consecuencia del PCA.

maximizan la información que se explica sobre la variable objetivo, en este caso el logaritmo del precio.

7. PCA y PPCA

Esta es la sección en la que más énfasis se hará, esto ya que corresponde a la temática de este corte. Se separará en 3 secciones: una dedicada a PCA, otra a PPCA y la última consiste en una comparación de modelos.

7.1. PCA

7.1.1. Variables a utilizar en PCA

Para iniciar el proceso de PCA se seleccionaron variables de modo que sean continuas o que sean variables en principio discretas, pero que por su rango amplio pueden ser tomadas (en la práctica) como continuas; esto se hace por la falta de variables totalmente continuas en la base de datos. Dicho esto, las variables usadas para PCA fueron las que muestra la siguiente tabla.

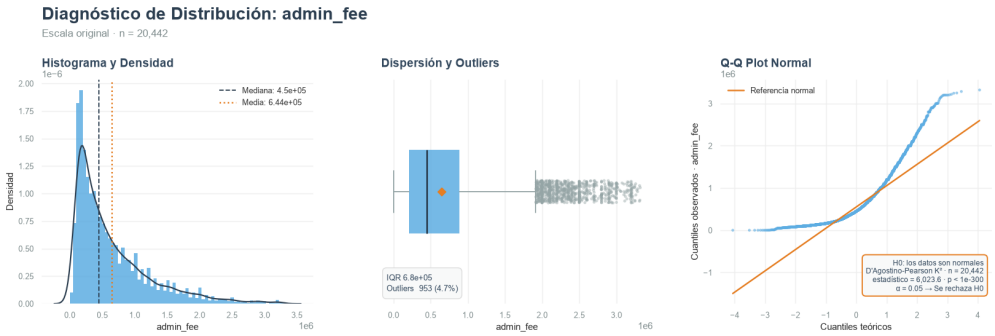
Variable	Valores únicos
price_amount	1,638
admin_fee	9,244
latitude	16,126
longitude	15,913
locality_frec	19
n_amenities	65
neighborhood_grouped_frec	20
dist_nearest_positive_km	16,220
dist_nearest_negative_km	16,220
area_built_m2	4,971

Tabla 4. Variables usadas para ajustar el PCA. Se incluyen algunas variables discretas con suficientes valores únicos (10 o más).

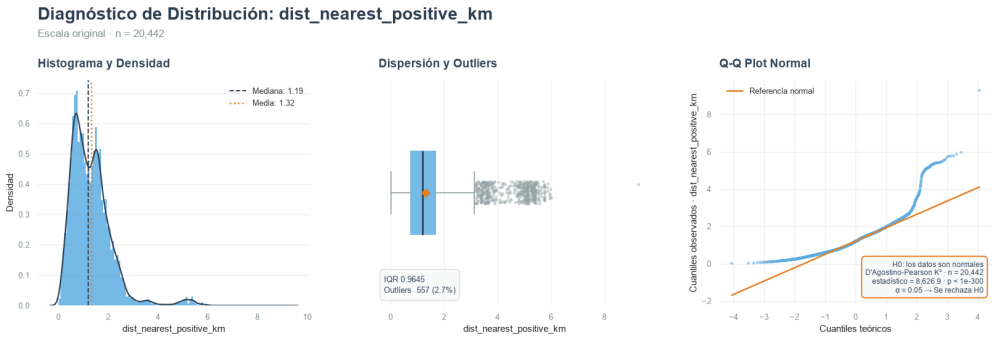
7.1.2. Análisis de escala para PCA

En este conjunto de datos un problema crucial es la disparidad de escalas, ya que se tienen variables como la cuota de administración (admin_fee) que están en cientos de miles o incluso millones, y otras variables que están en kilómetros, tales como dist_nearest_positive_km.[1] Por lo tanto, se plantean dos formas de ajustar PCA: la primera consta en estandarizar las variables tal como están, ver cómo se comportan sus componentes y qué tan grande es el error de reconstrucción; y la segunda consta en primero aplicar transformaciones como logaritmos, esto con el fin de aproximar las variables a una campana, y después estandarizar (para hacer más estable el proceso de estandarizar). Se plantea como única posibilidad la estandarización para asegurarse de obtener media 0 y trabajar así el PCA utilizando la matriz de correlaciones.

[1] Se generaron 2 variables nuevas basadas en la distancia a puntos de plusvalía o pérdida de valor de la ciudad.



(a) Escala de las tarifas de administración (millones o cientos de miles).



(b) Escala de las distancias a los puntos de plusvalía.

Figura 8. Escalas de las variables usadas en el PCA.

7.1.3. PCA estandarizando las variables sin transformar

En esta prueba las variables fueron escaladas en su forma original; posteriormente se aplicó PCA y se evaluó cuántos componentes utilizar, bajo el criterio de conservar por lo menos el 80 % de la variabilidad.

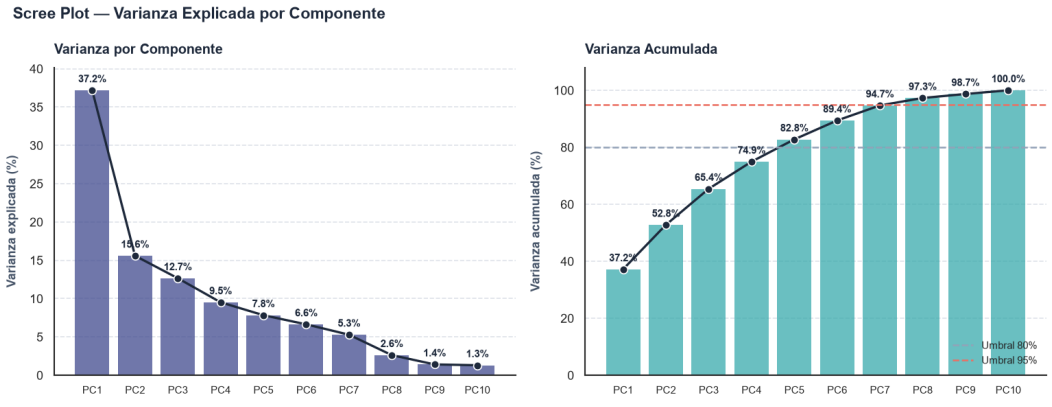


Figura 9. Varianzas explicadas por cada componente y acumulada.

Usando dicho criterio, es claro que se deben utilizar 5 componentes que conjuntamente explican el 82.8 % de la variabilidad, siendo la más explicativa aquella que explica el 37.2 % de la variabilidad. Esta decisión supone descartar 5 componentes, generando de esta manera una reducción importante de la dimensionalidad a costa de una leve

pérdida de información.

Al tener el ajuste final del modelo se pueden interpretar las componentes de la siguiente manera.

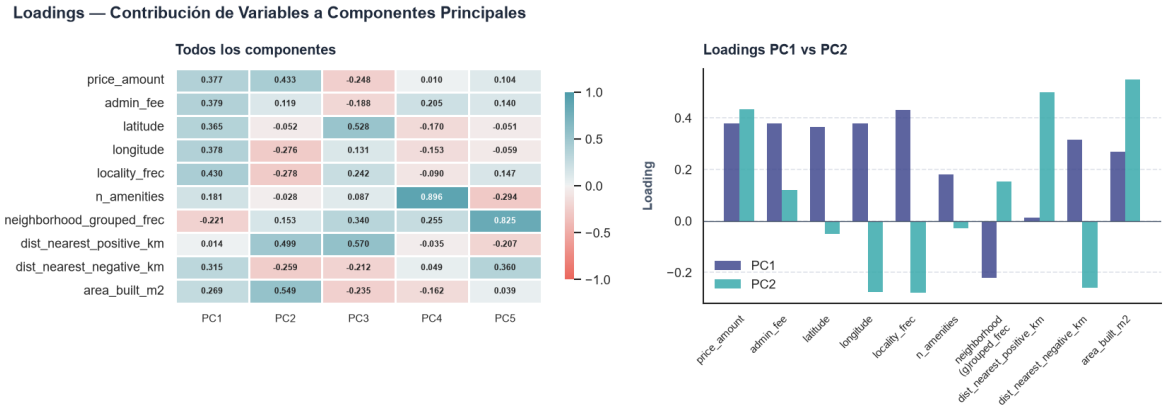


Figura 10. Matriz de *loadings* del primer PCA ajustado.

La primera componente combina características económicas y geográficas de los inmuebles, describiendo viviendas con precios, cuotas de administración y tamaños elevados relacionados con su ubicación, mientras que PC2 representa a viviendas alejadas de landmarks positivos y cercanas a puntos negativos, con una consideración mayor del tamaño del inmueble. Además, es posible apreciar cómo es que PC1 y PC2 parecen ir en dirección contraria respecto a las coordenadas; esto sugiere que describen espacios diferentes de la ciudad.

Por otro lado, la tercera componente describe viviendas económicas, con administración baja, y PC4, viviendas con muchas amenidades, ubicadas en barrios más frecuentes en la muestra.

Por último, PC5 representa viviendas en barrios más frecuentes, con menos amenidades y alejadas de landmarks negativos.

7.1.4. PCA estandarizando las variables transformadas

En esta iteración se repitió el mismo proceso de PCA, pero transformando previamente las variables con un fuerte sesgo utilizando un logaritmo.

Variables	
`price_amount`	`n_amenities`
`admin_fee`	`dist_nearest_positive_km`
`latitude`	`dist_nearest_negative_km`
`longitude`	`area_built_m2`

Tabla 5. Variables con distribución sesgada.

Adicionalmente, se vuelven a utilizar 5 componentes, ya que en este caso explican aproximadamente el 82 % de la varianza.

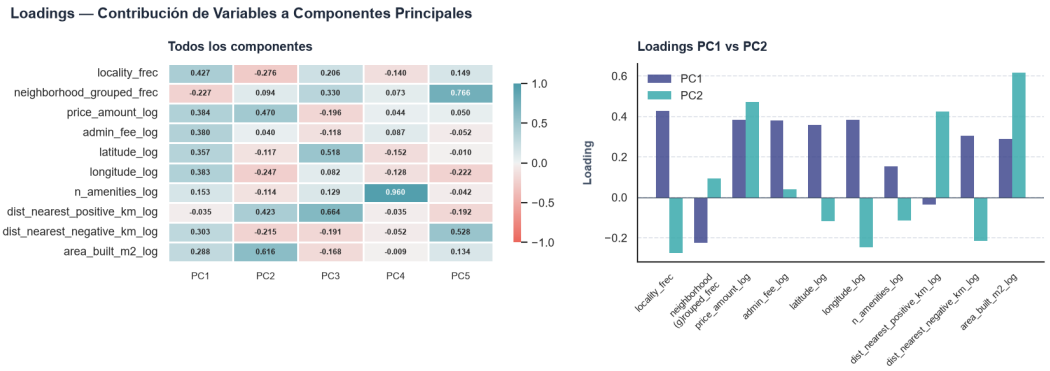


Figura 11. Matriz de *loadings* del segundo PCA ajustado.

La primera componente combina características económicas y geográficas de los inmuebles: describe viviendas con precios, cuotas de administración y tamaños elevados, ubicadas en localidades más frecuentes en la muestra y relativamente alejadas de landmarks negativos. PC2, en cambio, representa viviendas de gran tamaño y precio alto, alejadas de landmarks positivos y más cercanas a puntos negativos, ubicadas en localidades menos frecuentes. Además, PC1 y PC2 tienen signos opuestos en la latitud y la longitud, lo que sugiere que describen zonas diferentes de la ciudad.

Por otro lado, la tercera componente describe viviendas alejadas de landmarks positivos y ubicadas hacia el norte (latitud alta), en barrios más frecuentes, con precios y tamaños menores. PC4 está dominada casi por completo por el número de amenidades, por lo que representa viviendas con muchas amenidades sin una relación clara con su ubicación ni con su precio.

Por último, PC5 representa viviendas en barrios más frecuentes en la muestra, alejadas de landmarks negativos y algo más cercanas a los positivos, con una ligera tendencia hacia menores valores de longitud.

Más adelante en el documento se compararán los comportamientos de reconstrucción.

7.2. PPCA

En esta sección se retomarán los 2 paradigmas que se tenían antes, con las variables sin transformar y transformando las variables (con logaritmos). Adicionalmente, es importante destacar que se usará la misma cantidad de factores latentes, ya que se heredan las direcciones de PCA y por lo tanto la variabilidad que explica cada una de ellas.

7.2.1. PPCA estandarizando las variables sin transformar

En esta oportunidad se obtuvo la siguiente matriz de factores latentes $\hat{W}$, donde cada columna corresponde a un factor latente, es decir, estructura de los datos que no se ve en primera instancia y permite resumir el espacio en uno de menor dimensionalidad.

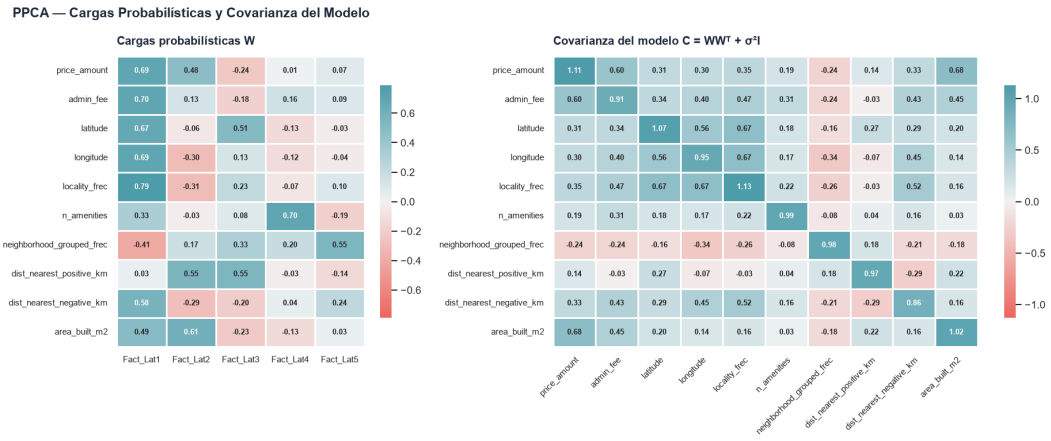


Figura 12. Matriz $\hat{W}$ del PPCA que hereda las direcciones del primer PCA ajustado.

En esta oportunidad la varianza del residuo corresponde a ≈ 0.348; esto es el ruido que se obtuvo al descartar las 5 componentes que fueron descartadas, pues esa información ahora actúa como ruido que el modelo no es capaz de explicar. Note cómo la diagonal es diferente de 1 a pesar de basarse en datos estandarizados (en PCA originalmente sería diagonal 1 al ser una matriz de correlación); eso indica que la estructura de $\hat{C}$ considera la variabilidad que el modelo no explica.

Adicionalmente, la matriz $\hat{W}$ cambia respecto a la Q_k de PCA, pues esta ahora incluye el ruido del residuo que no explica el modelo probabilístico. Luego se tiene que:

- El primer factor actúa como un descriptor de la escala del inmueble, tal que será más grande mientras el inmueble sea más caro, grande y con más amenidades; además, también se ve potenciado si la distancia a un `landmark` negativo es alta. **Luego describe casas costosas, grandes, cerca de varias amenidades, que además están al nororiente de la ciudad (latitud y longitud más grandes o cercanas a 0 desde la escala negativa)**.
- El segundo factor describe principalmente la geolocalización del inmueble: será grande si este está lejos de un `landmark` positivo y más cerca de uno negativo; además se ve potenciado al tener longitudes altas, es decir, se ve potenciado por viviendas que quedan más al oriente; además se ve potenciado por localidades frecuentes en la muestra (se codificaron con *frequency encoding* y eran Suba y Usaquén). Por lo tanto, describe **viviendas más al oriente con una cercanía mayor a un punto negativo que a uno positivo, pero que mantienen un buen tamaño**.

- El tercero describe viviendas pequeñas que están lejos de los `landmark` positivos y cerca de los negativos; adicionalmente, son más económicas y poseen administraciones bajas. Describe inmuebles modestos pero que a su vez son más económicos.
- El cuarto netamente describe cuántas amenidades reportó un inmueble.
- El quinto principalmente describe el vecindario del inmueble.

7.2.2. PPCA estandarizando las variables transformadas

Se recuperaron las direcciones del segundo PCA para posteriormente ser usadas en PPCA.

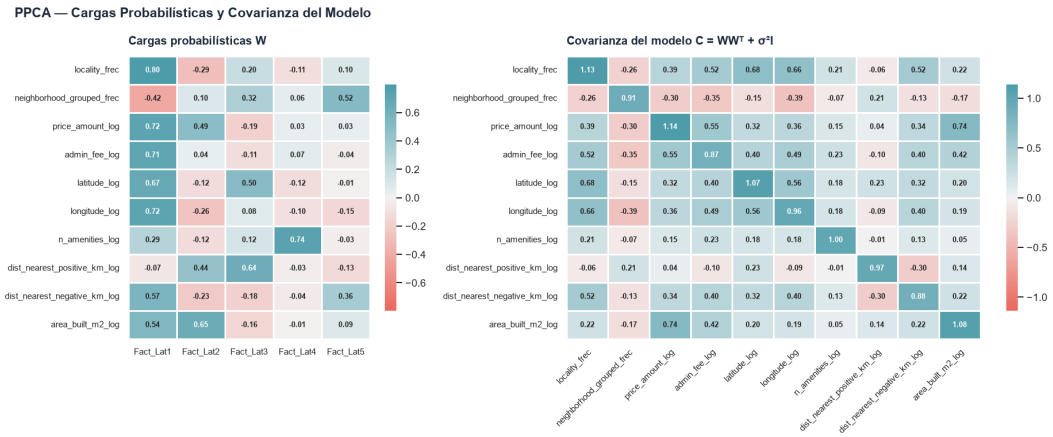


Figura 13. Matriz $\hat{W}$ del PPCA que hereda las direcciones del segundo PCA ajustado.

La interpretación es similar en los factores latentes, solo que con números ligeramente distintos; esto debido a que se usaron las `log_variables` en lugar de estas sin transformar, aunque este modelo y el PCA que también usó esas variables tienen un serio problema, que es que las coordenadas se tuvieron que desplazar y comprimir, por lo que se sacrifica interpretabilidad. Adicionalmente, como la información que se perdió fue similar, la varianza del residuo también lo es, ya que en este modelo es aproximadamente de 0.3434.

7.3. Comparar reconstrucciones

En esta sección se da paso a una comparación de los modelos utilizando el error cuadrado medio de reconstrucción y ese mismo error, pero desagregado por variable; esto con el fin de ver cómo se comporta el modelo con cada una de las variables.

Note que los MSE globales son similares en todos los modelos (del mismo tipo); eso ya que todos describen los mismos datos (o transformaciones de estos) con el mismo número

Método	Variables	MSE global	σ^2 residual
PCA	Originales	0.1724	—
PCA	Log	**0.1717**	—
PPCA	Originales	0.2203	0.3448
PPCA	Log	0.2194	0.3434

Tabla 6. MSE global de reconstrucción por método y tipo de variables. La varianza residual σ^2 solo está definida para el PPCA.

	PCA		PPCA		
Variable	**Original**	**Log**	**Original**	**Log**	**Mejor modelo**
`admin_fee`	**0.3431**	0.4181	0.3604	0.4253	PCA original
`area_built_m2`	0.1653	**0.0839**	0.1993	0.1227	PCA log
`dist_nearest_negative_km`	0.3657	**0.3078**	0.3982	0.3589	PCA log
`dist_nearest_positive_km`	0.1651	**0.1448**	0.2213	0.2057	PCA log
`latitude`	**0.1171**	0.1272	0.1518	0.1600	PCA original
`locality_frec`	**0.0951**	0.1001	0.1166	0.1217	PCA original
`longitude`	0.3039	**0.2864**	0.3193	0.3058	PCA log
`n_amenities`	0.0362	**0.0117**	0.1515	0.1323	PCA log
`neighborhood_grouped_frec`	**0.0398**	0.1732	0.1656	0.2719	PCA original
`price_amount`	0.0925	**0.0636**	0.1188	0.0903	PCA log

Tabla 7. MSE de reconstrucción por variable para cada método. En negrita, el menor MSE de cada variable.

de componentes. Aún más interesante es ver que los errores de reconstrucción de PPCA por lo general son mayores; esto se debe a que PPCA también considera la variabilidad que no pueden explicar sus componentes (W y M contienen un término de variabilidad residual σ^2). A pesar de que en un principio PCA podría parecer ganarle a PPCA por eso, este último incorpora la capacidad generativa de datos que además permite saber cómo van a distribuirse las observaciones y permite interpretar las columnas de W como factores latentes no observados para comprender mejor la estructura de los datos; además, PPCA tiene en cuenta la variabilidad que no puede explicar y la toma como un factor de ruido, por lo que también se puede descomponer en efectos.

Luego, cada modelo tiene su uso: PCA para describir direcciones de manera determinística y probar el preprocesamiento de datos, y PPCA para estimar probabilidades, reconocer cómo se distribuyen los datos y generar un espacio latente que permite interpretar factores latentes como estructura no vista de la cual se puede estimar cuánto es señal y cuánto ruido.

8. Conclusión

El mercado inmobiliario de Bogotá y alrededores tiene viviendas cuyos precios están determinados por una mezcolanza de características físicas del inmueble, como su tamaño y número de baños o parqueaderos, y también por su locación, como a qué municipio o localidad pertenece. Con esto último es posible diferenciar la ciudad en zonas con diferencias muy marcadas, tanto en su estrato, precios y tamaños, de ahí derivándose los perfiles expuestos anteriormente. Adicionalmente, las viviendas en la ciudad se pueden representar en menor dimensionalidad con factores latentes que por lo general tienen un comportamiento marcado por cada tipo de inmueble, pues al primer factor por lo general se le asigna la escala del inmueble y su precio, es decir, crecerá con inmuebles de lujo. La segunda corresponde a inmuebles en otra zona de la ciudad pero igualmente con un precio elevado, y por último la tercera suele actuar como contraste, ya que describe inmuebles de un precio y tamaño más modestos. Además, fue posible ajustar una recta con un alto R^2, lo cual indica la alta asociación de las características mencionadas con la variable de interés precio.

Referencias

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., Fernández del Río, J., Wiebe, M., Peterson, P., Gérard-Marchant, P., Sheppard, K., Reddy, T., Weckesser, W., Abbasi, H., Gohlke, C., and Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585(7825):357–362.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3):90–95.

McKinney, W. (2010). Data structures for statistical computing in Python. In van der Walt, S. and Millman, J., editors, *Proceedings of the 9th Python in Science Conference*, pages 56–61.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

Seabold, S. and Perktold, J. (2010). statsmodels: Econometric and statistical modeling with Python. In van der Walt, S. and Millman, J., editors, *Proceedings of the 9th Python in Science Conference*, pages 92–96.

The pandas development team (2020). pandas-dev/pandas: Pandas.

Virtanen, P., Gommers, R., Oliphant, T. E., Haberland, M., Reddy, T., Cournapeau, D., Burovski, E., Peterson, P., Weckesser, W., Bright, J., van der Walt, S. J., Brett, M., Wilson, J., Millman, K. J., Mayorov, N., Nelson, A. R. J., Jones, E., Kern, R., Larson, E., Carey, C. J., Polat, İ., Feng, Y., Moore, E. W., VanderPlas, J., Laxalde, D., Perktold, J., Cimrman, R., Henriksen, I., Quintero, E. A., Harris, C. R., Archibald, A. M., Ribeiro, A. H., Pedregosa, F., van Mulbregt, P., and SciPy 1.0 Contributors (2020). SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3):261–272.

Waskom, M. L. (2021). seaborn: statistical data visualization. *Journal of Open Source Software*, 6(60):3021.